

SPRAWOZDANIE NR 2			
Nazwa ćwiczenia	Lab 03 - Wyżarzanie		 POLITECHNIKA BYDGOSKA Wydział Telekomunikacji, Informatyki i Elektrotechniki
Przedmiot	Fundamenty natywnej i generatywnej sztucznej inteligencji		
Student grupa	Piotr Przymus 127902 Grupa 3		
Data ćwiczeń	17.03.2026	31.03.2026	Data oddania sprawozdania

Celem ćwiczenia było zaimplementowanie oraz porównanie trzech algorytmów optymalizacji:

- Simulated Annealing (SA),
- Particle Swarm Optimization,
- Genetic Algorithm (GA).

Algorytmy zostały zastosowane do rozwiązania problemu komiwojażera (TSP) dla zbioru danych berlin52 pochodzącego z biblioteki TSPLIB.

Należało porównać:

- jakość uzyskiwanych rozwiązań (długości trasy),
- stabilność algorytmów,
- czas działania.

Implementacja algorytmów

Wyżarzanie

Algorytm wyżarzania symulowanego jest metodą inspirowaną procesem fizycznego chłodzenia metali.

Algorytm rozpoczyna od losowej trasy, a następnie generuje nowe rozwiązania poprzez niewielkie modyfikacje (zamianę dwóch miast). Jeżeli nowe rozwiązanie jest lepsze, zostaje przyjęte. Jeżeli jest gorsze, może zostać zaakceptowane z pewnym prawdopodobieństwem zależnym od temperatury.

Wraz z kolejnymi iteracjami temperatura maleje, co zmniejsza prawdopodobieństwo akceptacji gorszych rozwiązań.

Parametry użyte przeze mnie w eksperymencie:

- temperatura początkowa: 1000
- współczynnik chłodzenia: 0.995
- minimalna temperatura: 1

Algorytm genetyczny

Algorytm genetyczny jest metodą inspirowaną procesem ewolucji biologicznej. Rozwiązania reprezentowane są jako osobniki w populacji. W każdej iteracji wykonywane są operacje:

- selekcji najlepszych osobników,

- krzyżowania,
- mutacji.

W implementacji zastosowano:

- reprezentację permutacyjną trasy,
- krzyżowanie typu ordered crossover,
- mutację polegającą na zamianie dwóch miast.

Parametry użyte przeze mnie w eksperymencie:

- wielkość populacji: 100,
- liczba generacji: 500,
- prawdopodobieństwo mutacji: 0.1.

Particle Swarm Optimization

PSO jest algorytmem inspirowanym zachowaniem stad zwierząt, takich jak ptaki. W klasycznej wersji PSO operuje się wektorami ciągłymi. W przypadku TSP konieczna jest adaptacja do przestrzeni permutacji.

W implementacji zastosowano uproszczoną adaptację polegającą na:

- reprezentowaniu cząstek jako permutacji miast,
- wykonywaniu losowych operacji swap,
- aktualizacji najlepszego rozwiązania osobistego (pbest),
- aktualizacji najlepszego rozwiązania globalnego (gbest).

Parametry użyte przeze mnie w eksperymencie:

- liczba cząstek: 30,
- liczba iteracji: 1000.

Eksperymenty


Każdy algorytm został uruchomiony 10 razy, aby uwzględnić wpływ losowości. Dla każdego algorytmu obliczono:

- najlepszy wynik,
- średni wynik,
- odchylenie standardowe,
- najgorszy wynik,
- średni czas wykonania.


Algorytm	Najlepszy wynik	Średni wynik	Najgorszy wynik	Odchylenie standardowe	Średni czas [s]
SA	12526.12	13109.77	14138.12	551.92	0.04
PSO	22592.69	23320.75	23837.16	372.47	0.81
GA	9281.87	10389.67	11873.45	655.83	2.46

Wizualizacja tras


SA



PSO



GA (najlepszy)



Analiza wyników

1. Który algorytm uzyskał najlepszą trasę?

Najlepszy wynik uzyskał algorytm genetyczny (GA) z długością trasy 9281.87. Algorytm ten dzięki operacjom krzyżowania i mutacji efektywnie eksploruje przestrzeń rozwiązań i potrafi znaleźć lepsze kombinacje tras.

2. Który algorytm był najbardziej stabilny?

Najbardziej stabilnym algorytmem był PSO, ponieważ uzyskał najmniejsze odchylenie standardowe (372.47) - czyli wyniki pomiędzy kolejnymi uruchomieniami były najbardziej zbliżone.

3. Jak parametry SA wpływają na wynik?

Mają istotny wpływ na jakość rozwiązania:

- większa temperatura początkowa umożliwia eksplorację większej części przestrzeni rozwiązań,
- wolniejsze chłodzenie pozwala uniknąć utknięcia w lokalnym minimum,
- większa liczba iteracji zwiększa szansę znalezienia lepszego rozwiązania

Zbyt szybkie chłodzenie może spowodować przedwczesną zbieżność.

4. Jakie trudności pojawiają się przy adaptacji PSO do problemu permutacyjnego?

PSO jest algorytmem zaprojektowanym dla przestrzeni ciągłych. W przypadku TSP pojawiają się trudności związane z:

- reprezentacją rozwiązania jako permutacji,
- brakiem naturalnego pojęcia prędkości,
- koniecznością stosowania operacji swap zamiast standardowej aktualizacji pozycji.

Zastosowana implementacja była uproszczona, co prawdopodobnie wpłynęło na słabsze wyniki PSO.

5. Który algorytm wybrał(a)byś do większych instancji TSP?

Wybrałbym algorytm genetyczny, ponieważ:

- uzyskał najlepsze wyniki jakościowe,
- dobrze radzi sobie z dużą przestrzenią rozwiązań,
- jest łatwy do rozszerzenia o bardziej zaawansowane operatory krzyżowania i mutacji.

Jednak jego wadą jest dłuższy czas działania.