

Ocena atrakcyjności inwestycji przy użyciu systemu wnioskowania rozmytego

Piotr Przymus 127902

3 maja 2026

1 Wprowadzenie

Celem pracy było zaprojektowanie systemu wnioskowania rozmytego wspomagającego ocenę atrakcyjności inwestycji. Model został zaimplementowany z wykorzystaniem biblioteki jFuzzy-Logic oraz standardu FCL (Fuzzy Control Language).

2 Opis problemu i zmienne

Ocena atrakcyjności inwestycji polega na określeniu, czy dana inwestycja jest opłacalna, biorąc pod uwagę możliwy zysk, ryzyko oraz dostępność środków. W praktyce decyzje inwestycyjne rzadko są jednoznaczne, ponieważ poszczególne czynniki często mają charakter nieprecyzyjny (np. „wysokie ryzyko” czy „dobra płynność”).

Celem zaprojektowanego systemu jest wspomaganie takiej decyzji poprzez połączenie kilku kluczowych parametrów w jedną syntetyczną ocenę atrakcyjności. System nie zastępuje decyzji inwestora, ale stanowi narzędzie pomocnicze, które porządkuje informacje i ułatwia porównywanie różnych wariantów.

W modelu uwzględniono trzy zmienne wejściowe:

- **Oczekiwana stopa zwrotu** (*expected_return*) - określa potencjalny zysk z inwestycji;
- **Poziom ryzyka** (*risk*) - opisuje niepewność i możliwość poniesienia strat;
- **Płynność** (*liquidity*) - informuje, jak łatwo można wycofać środki z inwestycji.

Zmienne te zostały dobrane tak, aby odzwierciedlały najważniejsze aspekty decyzji inwestycyjnej, czyli relację między zyskiem a bezpieczeństwem oraz dostępnością kapitału.

Zmienna wyjściowa:

- **Atrakcyjność** (*attractiveness*) - końcowa ocena inwestycji w skali 0–100, interpretowana lingwistycznie jako niska, średnia lub wysoka.

Zastosowanie logiki rozmytej pozwala na uwzględnienie nieprecyzyjnych pojęć oraz wiedzy eksperckiej wyrażonej w postaci reguł językowych. Dzięki temu model lepiej odzwierciedla rzeczywisty proces podejmowania decyzji niż klasyczne podejścia oparte wyłącznie na sztywnych progach liczbowych.

Funkcje przynależności oraz ich parametry zostały zdefiniowane w pliku FCL `investment.fcl`.

3 Definicja zmiennych lingwistycznych

W systemie rozmytym wykorzystano cztery zmienne lingwistyczne: trzy wejściowe i jedną wyjściową. Każda zmienna została opisana zakresem wartości, zbiorami lingwistycznymi oraz funkcjami przynależności zdefiniowanymi w pliku FCL.

3.1 Zmienna *expected_return*

- zakres: $[0, 30]$,
- wartości lingwistyczne: *low*, *medium*, *high*,
- funkcje przynależności: trapezowe i trójkątne, zdefiniowane w `investment.fcl`.

3.2 Zmienna *risk*

- zakres: $[0, 10]$,
- wartości lingwistyczne: *low*, *medium*, *high*,
- funkcje przynależności: trapezowe i trójkątne, zdefiniowane w `investment.fcl`.

3.3 Zmienna *liquidity*

- zakres: $[0, 10]$,
- wartości lingwistyczne: *low*, *medium*, *high*,
- funkcje przynależności: trapezowe i trójkątne, zdefiniowane w `investment.fcl`.

3.4 Zmienna wyjściowa *attractiveness*

- zakres: $[0, 100]$,
- wartości lingwistyczne: *low*, *medium*, *high*,
- funkcje przynależności: trapezowe i trójkątne, zdefiniowane w `investment.fcl`.

Tak zdefiniowane zmienne pozwalają przełożyć jakościowe oceny inwestycji na model rozmyty, w którym reguły eksperckie mogą łączyć informację o potencjalnym zysku, ryzyku i płynności w jedną syntetyczną ocenę atrakcyjności.

Formalnie każda zmienna lingwistyczna została zdefiniowana jako piątka $L = (X, T(X), U, G, M)$, gdzie X oznacza nazwę zmiennej, $T(X)$ zbiór wartości lingwistycznych, U uniwersum rozważań, G reguły generowania nazw, natomiast M odwzorowanie przypisujące funkcje przynależności.

4 Baza reguł

Zdefiniowano 11 reguł rozmytych. Jest to model uproszczony, czyli nie obejmuje wszystkich możliwych kombinacji trzech wartości lingwistycznych dla trzech zmiennych (takich kombinacji byłoby 27), lecz tylko najistotniejsze i najbardziej reprezentatywne przypadki decyzyjne. Dzięki temu model jest czytelniejszy, łatwiejszy do interpretacji i prostszy w utrzymaniu.

Reguły sformułowano zgodnie z intuicją dotyczącą relacji między zmiennymi: niska stopa zwrotu połączona z wysokim ryzykiem lub niską płynnością obniża atrakcyjność, a odwrotne warunki ją podwyższają. Reguły pośrednie (np. mieszanka średnich i wysokich wartości wejść) pozwalają uzyskać wartości pośrednie wyjściowe.

Pełna baza reguł:

Nr	Reguła
1	IF <i>expected_return</i> IS <i>low</i> AND <i>risk</i> IS <i>high</i> THEN <i>attractiveness</i> IS <i>low</i>
2	IF <i>expected_return</i> IS <i>low</i> AND <i>liquidity</i> IS <i>low</i> THEN <i>attractiveness</i> IS <i>low</i>
3	IF <i>expected_return</i> IS <i>medium</i> AND <i>risk</i> IS <i>medium</i> AND <i>liquidity</i> IS <i>medium</i> THEN <i>attractiveness</i> IS <i>medium</i>

- 4 IF expected_return IS high AND risk IS low AND liquidity IS high THEN attractiveness IS high
 - 5 IF expected_return IS high AND risk IS medium THEN attractiveness IS medium
 - 6 IF expected_return IS medium AND risk IS low THEN attractiveness IS high
 - 7 IF expected_return IS high AND liquidity IS low THEN attractiveness IS medium
 - 8 IF risk IS high AND liquidity IS low THEN attractiveness IS low
 - 9 IF expected_return IS low AND risk IS low AND liquidity IS high THEN attractiveness IS medium
 - 10 IF expected_return IS medium AND liquidity IS high THEN attractiveness IS high
 - 11 IF expected_return IS high AND risk IS high THEN attractiveness IS medium
-

Z punktu widzenia interpretacji eksperckiej reguły 1–2 odzwierciedlają sytuacje niekorzystne, reguły 4, 6 i 10 opisują warunki atrakcyjne, a reguły 3, 5, 7, 8, 9, 11 stanowią przypadki pośrednie.

5 Metoda defuzyfikacji

Zastosowano metodę środka ciężkości (COG) - jest ona jedną z najczęściej wykorzystywanych metod defuzyfikacji w systemach rozmytych.

W implementacji w jFuzzyLogic metoda jest ustawiona w sekcji DEFUZZIFY zmiennej wyjściowej:

```
METHOD : COG;  
DEFAULT := 0;
```

6 Eksperymenty i wyniki

Dla modelu uproszczonego dobrano 11 reprezentatywnych przypadków testowych, po jednym dla kluczowych reguł oraz przypadków brzegowych. Dla każdego terminu lingwistycznego przyjęto reprezentatywne wartości numeryczne (centra funkcji przynależności):

- ‘expected_return’: low=3.0, medium=10.0, high=20.0,
- ‘risk’: low=1.0, medium=5.0, high=10.0,
- ‘liquidity’: low=2.0, medium=5.0, high=8.0.

Wyniki eksperymentów zostały zarejestrowane w postaci danych liczbowych, obejmujących wartości zmiennych wejściowych oraz odpowiadające im wartości zmiennej wyjściowej.

6.1 Wyniki numeryczne

Analizę przeprowadzono na 11 przypadkach odpowiadających wybranym, najbardziej reprezentatywnym kombinacjom wejść. Podstawowe statystyki atrakcyjności to:

- liczba przypadków: 11,
- wartość minimalna: 0.00,
- wartość maksymalna: 80.53,
- wartość średnia: około 50.02.

Rozkład wyników wykazuje skupienia w trzech typowych poziomach: wartości niskie (około 0–20), wartości średnie (około 50) oraz wysokie (około 80). To zachowanie jest konsekwencją

zastosowanych funkcji przynależności, operatorów logicznych (AND=MIN) oraz metody akumulacji (MAX) i defuzyfikacji (COG). W praktyce oznacza to, że model rozpoznaje zarówno sytuacje niekorzystne, neutralne, jak i wyraźnie atrakcyjne.

Interpretacja lingwistyczna wyników została wykonana na podstawie dominującego stopnia przynależności do zbiorów rozmytych. Wartości pośrednie mogą należeć do więcej niż jednego zbioru, jednak przypisywane są do tego, dla którego stopień przynależności jest największy.

6.2 Tabela (opisowa)

W tabeli poniżej przedstawiono 11 przypadków testowych w formie opisowej.

Table 2: Wyniki (opisowo) dla modelu uproszczonego

Lp.	Stopa zwrotu	Ryzyko	Płynność	Atrakcyjność
1	niska	wysoki	niska	niska
2	niska	niski	niska	niska
3	średnia	średni	średnia	średnia
4	wysoka	niski	wysoka	wysoka
5	wysoka	średni	średnia	średnia
6	średnia	niski	średnia	wysoka
7	wysoka	wysoki	niska	niska
8	średnia	wysoki	niska	niska
9	niska	niski	wysoka	średnia
10	średnia	średni	wysoka	wysoka
11	wysoka	wysoki	średnia	średnia

7 Analiza i wnioski

Uzyskane wyniki pokazują, że model działa zgodnie z przyjętymi założeniami.

- niska stopa zwrotu połączona z wysokim ryzykiem i niską płynnością prowadzi do niskiej atrakcyjności inwestycji,
- wysoka stopa zwrotu przy niskim ryzyku i wysokiej płynności daje wysoką ocenę atrakcyjności,
- przypadki pośrednie generują wyniki średnie, zależne od aktywowanych reguł.

Można zauważyć, że system poprawnie rozróżnia inwestycje niekorzystne, neutralne oraz atrakcyjne. Najwyższe wartości pojawiają się dla inwestycji o korzystnym stosunku zysku do ryzyka, natomiast najniższe dla konfiguracji o dużym ryzyku i słabych pozostałych parametrach.

Wyniki około 50 odpowiadają przypadkom mieszanym, w których część parametrów jest korzystna, a część nie. Pokazuje to, że system nie podejmuje decyzji w sposób zero-jedynkowy, lecz uwzględnia stopień spełnienia poszczególnych warunków.

Zaprojektowany model jest prosty, czytelny i łatwy do interpretacji. Daje wyniki zgodne z intuicją i pozwala w prosty sposób porównywać różne warianty inwestycji. Można go rozszerzyć o większą liczbę reguł lub dostrojenie funkcji przynależności na podstawie danych historycznych.

8 Wizualizacja funkcji przynależności

Poniżej przedstawiono wykresy funkcji przynależności dla wszystkich zmiennych wykorzystanych w modelu - łatwo zauważyć zakresy aktywacji.




Figure 1: Funkcje przynależności dla zmiennej wejściowej: oczekiwana stopa zwrotu




Figure 2: Funkcje przynależności dla zmiennej wejściowej: ryzyko




Figure 3: Funkcje przynależności dla zmiennej wejściowej: płynność




Figure 4: Funkcje przynależności dla zmiennej wyjściowej: atrakcyjność